



MINERIA DE DATOS

A Y U D A N T I A 2
A L A N M O L I N A



OBJETIVOS:

- Estadística.
- Distribución de Probabilidad.
- Probabilidad Condicional.
- Histogramas y Ajustes Gaussianos.
- Correlación.
- Correlación de Pearson.

INTRODUCCION A LA ESTADISTICA EN MINERIA DE DATOS



La minería de datos es una técnica que se utiliza para extraer información importante de los datos. Se basa en gran medida en la estadística, ya que permite encontrar patrones, correlaciones y perspectivas en grandes conjuntos de datos.

ESTADISTICA DESCRIPTIVA



01

Promedio:

La media aritmética es el valor promedio de un conjunto de datos.
El valor más representativo.

02

Mediana:

La mediana es el valor que se encuentra en el centro de los datos cuando están ordenados.

03

Moda:

La moda es el valor que aparece con mayor frecuencia en el conjunto de datos.
El que más se repite.

ESTADISTICA DESCRIPTIVA



01

Varianza:

La varianza mide cuánto se dispersan los datos con respecto a la media.

02

Desviación Estándar:

La desviación estándar indica cuánto se desvían los valores con respecto a la media.

03

Coeficiente de Correlación de Pearson:

Mide la relación entre dos variables (X, Y), su valor está entre -1 y 1, -1 indica correlación perfecta negativa, 0 indica nula correlación y 1 indica correlación perfecta positiva.

PROBABILIDAD CONDICIONAL Y NO CONDICIONAL

- ¿Qué es una probabilidad condicional?: Es la probabilidad de que ocurra un evento A, dado que sabemos que otro evento B ha ocurrido. Se denota como $P(A|B)$ y se lee "la probabilidad de A dado B".
- ¿Qué es una probabilidad incondicional?: Se refiere a la probabilidad de un evento sin tener en cuenta ninguna otra información. Ej: ¿La probabilidad de lanzar un dado y que salga un numero Par?

Probabilidad condicionada

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

MAPAS DE CALOR

Un mapa de calor es una representación gráfica de datos que usa colores para mostrar valores. Los mapas de calor son una técnica popular para visualizar datos y permiten identificar patrones y anomalías.





GRÁFICO DE DISPERSIÓN

Un diagrama de dispersión es una representación gráfica de la relación entre dos variables, muy utilizada en las fases de Comprobación de teorías e identificación de causas raíz y en el Diseño de soluciones y mantenimiento de los resultados obtenidos.




CORRELACIÓN

La correlación entre dos variables es una medida estadística que indica la fuerza y dirección de la relación lineal entre ellas, es decir, si tienden a variar juntas (positiva) o en direcciones opuestas (negativa).

Correlación positiva:
Cuando una variable aumenta, la otra también tiende a aumentar.

Correlación negativa:
Cuando una variable aumenta, la otra tiende a disminuir.



CORRELACIÓN

Fuerza de la correlación:

Se mide con el coeficiente de correlación, que puede variar entre -1 y +1. Un valor cercano a +1 o -1 indica una correlación fuerte. Un valor cercano a 0 indica una correlación débil o inexistente.

No implica causalidad:

Una correlación no significa que una variable cause la otra, solo indica que están relacionadas.

Ejemplos:

La altura de una persona y su peso (correlación positiva).

El precio de un producto y la cantidad demandada (correlación negativa).


La cantidad de horas de estudio y la nota en un examen (correlación positiva).

DISTRIBUCION DE PROBABILIDAD

Una distribución de probabilidad describe cómo se distribuyen los valores de una variable aleatoria en un conjunto de datos. Nos indica qué valores son más probables y cómo se comporta la variable en el tiempo.

Distribuciones Discretas: Para variables que toman valores específicos y contables (como el número de clientes en un negocio).

Distribuciones Continuas: Para variables que pueden tomar infinitos valores en un rango (como la altura de las personas)





PRACTICA EN R

Alan Molina
alan.molina@pregrado.uoh.cl

