

COM4001-1 Minería de Datos

Profesor: Alex Digenova

Ayudante: Alan Molina H.



## Ayudantía 6

### Objetivos

- Árboles de decisión
- Métricas de división.
- Ejemplos.

### 1. Árboles de Decisión

#### 1.1. ¿Qué es un Árbol de Decisión?

Un árbol de decisión es un modelo de aprendizaje supervisado utilizado para **clasificación o regresión**. Funciona dividiendo los datos en subgrupos mediante preguntas secuenciales del tipo “¿la variable  $x$  cumple cierta condición?”, formando una estructura de árbol donde:

- Cada **nodo interno** representa una condición sobre un atributo.
- Cada **rama** representa el resultado de esa condición.
- Cada **hoja** representa una predicción (clase o valor numérico).

#### 1.2. ¿Cómo funciona?

1. Se parte con todos los datos en la **raíz** del árbol.
2. Se busca la mejor variable y el mejor valor de corte para dividir los datos.
3. Se crean dos ramas: una para los que cumplen la condición y otra para los que no.
4. Este proceso se repite recursivamente en cada rama.
5. El proceso se detiene cuando:
  - Todos los elementos son de la misma clase (nodo puro).
  - Se alcanza una profundidad máxima.
  - No hay ganancia significativa al seguir dividiendo.

### 1.3. Métricas para evaluar divisiones

#### 1.3.1. Impureza de Gini.

$$Gini = 1 - \sum_{i=1}^k p_i^2$$

donde  $p_i$  es la proporción de datos de la clase  $i$  en un nodo. El Gini es 0 cuando el nodo es puro.

#### 1.3.2. Entropía.

$$H = - \sum_{i=1}^k p_i \log_2(p_i)$$

Se utiliza en el algoritmo ID3. También mide el grado de mezcla de clases en un nodo.

### 1.4. Ventajas.

- Son fáciles de interpretar y visualizar.
- No requieren normalización ni estandarización.
- Admiten datos numéricos y categóricos.
- Capturan relaciones no lineales.

### 1.5. Desventajas.

- Pueden sobreajustarse (*overfitting*) si no se poda o regula su profundidad.
- Son sensibles a pequeñas variaciones en los datos.
- Solo generan divisiones ortogonales (no curvas).

### 1.6. Ejemplo 1: Árbol con variable categórica.

| Edad   | Estudia | Aprobó |
|--------|---------|--------|
| Joven  | Sí      | Sí     |
| Joven  | No      | No     |
| Adulto | Sí      | Sí     |
| Adulto | No      | No     |

Al dividir por la variable **Estudia**, se obtienen dos grupos puros:

- Estudia = Sí  $\rightarrow$  todos aprueban.

- Estudia = No  $\rightarrow$  todos reprueban.

**Árbol resultante:**

¿Estudia?

Sí  $\rightarrow$  Aprobó

No  $\rightarrow$  No aprobó

### 1.7. Ejemplo 2: Árbol con variable numérica.

| Horas de estudio | Aprobó |
|------------------|--------|
| 2                | No     |
| 4                | No     |
| 6                | Sí     |
| 8                | Sí     |
| 10               | Sí     |

Evaluando divisiones posibles, el mejor corte es en  $x = 5$ :

$$\text{¿Horas de estudio} \leq 5? \Rightarrow \begin{cases} \text{Sí} & \rightarrow \text{No aprobó} \\ \text{No} & \rightarrow \text{Aprobó} \end{cases}$$

**Árbol resultante:**

¿Horas de estudio  $\leq 5$ ?

Sí  $\rightarrow$  No aprobó

No  $\rightarrow$  Aprobó

## 2. Árboles de Decisión: Enunciados

**Ejercicio 1: Conjunto de Datos Reducido (5 datos).** Dado el siguiente conjunto de datos, determine la mejor partición de los datos para un árbol de decisión y calcule la función de costo asociada a dicha partición utilizando el índice de Gini:

| <b>X</b> | <b>Y</b> |
|----------|----------|
| -1.2     | 0        |
| 0.3      | 1        |
| -0.8     | 0        |
| 0.6      | 1        |
| 1.0      | 1        |

Determine:

- El mejor punto de corte sobre la variable **X** para particionar los datos.
- La función de costo total utilizando el índice de Gini.

**Ejercicio 2: Conjunto de Datos Extendido (9 datos).** Dado el siguiente conjunto de datos, determine la mejor partición de los datos para un árbol de decisión y calcule la función de costo asociada a dicha partición utilizando el índice de Gini:

| <b>X</b> | <b>Y</b> |
|----------|----------|
| 1.23     | 1        |
| -0.47    | 0        |
| 0.02     | 1        |
| 1.40     | 1        |
| 0.53     | 1        |
| -0.97    | 0        |
| 0.70     | 0        |
| -0.45    | 0        |
| 0.10     | 1        |

Determine:

- El mejor punto de corte sobre la variable **X** para particionar los datos.
- La función de costo total utilizando el índice de Gini.