

COM4001-1 Minería de Datos**Profesor:** Alex Digenova**Ayudante:** Alan Molina H.

Ayudantía 6

Objetivos

- Árboles de decisión
- Métricas de división.
- Ejemplos.

Actividad introductoria: ¿Cuándo buscamos cargador?

Supongamos que observamos a varias personas y registramos el porcentaje de batería de su celular junto con su decisión de buscar o no un cargador.

Batería (%)	Busca cargador
50	0
5	1
15	1
35	0
80	0
10	1

donde:

1 = Busca cargador

0 = No busca cargador

Pregunta 1.

Si tuvieras que hacer una sola pregunta para clasificar a una nueva persona, ¿cuál sería?, ¿qué patrón observas en los datos?

Idea esperada.

¿La batería es menor o igual a cierto porcentaje?

¿Batería $\leq 25\%$?

Pregunta 2.

¿Por qué esa pregunta puede servir para separar los casos?

Idea esperada.

Porque los casos con batería menor o igual a 25 % corresponden a personas que buscan cargador, mientras que los casos con batería mayor a 25 % corresponden a personas que no buscan cargador.

Pregunta 4.

¿Cómo se vería esta decisión como un árbol?

$$\text{¿Batería} \leq 25 \%? \Rightarrow \begin{cases} \text{Sí} \rightarrow \text{Busca cargador} \\ \text{No} \rightarrow \text{No busca cargador} \end{cases}$$

Pregunta 5.

¿Qué significa que una rama del árbol contenga casos de una sola clase?

Idea esperada.

Significa que esa rama es pura. Es decir, no hay mezcla de decisiones dentro de ese grupo.

Pregunta 6.

¿Qué pasaría si elegimos una mala pregunta, por ejemplo:

$$\text{¿Batería} \leq 7,5 \%?$$

Idea esperada.

El lado izquierdo tendría solo el caso de 5 %, pero el lado derecho mezclaría personas que sí buscan cargador con personas que no lo buscan. Por tanto, la separación no sería tan buena.

Pregunta 7.

Entonces, ¿qué busca hacer un árbol de decisión?

Idea esperada.

Un árbol de decisión busca encontrar preguntas que separen los datos en grupos lo más ordenados o puros posible.

Pregunta 8.

¿Cómo podríamos medir formalmente si una separación es buena o mala?

Idea esperada.

Necesitamos una medida de impureza. Si un grupo tiene clases mezcladas, su impureza es alta. Si un grupo contiene una sola clase, su impureza es baja o cero.

Puente hacia el método.

A partir de esta idea aparece el índice de Gini. El índice de Gini permite medir qué tan mezcladas están las clases dentro de un nodo.

$$Gini(D) = 1 - p_0^2 - p_1^2$$

donde p_0 es la proporción de casos de clase 0 y p_1 es la proporción de casos de clase 1.

Interpretación pedagógica.

Un nodo puro tiene Gini igual a cero. Esto significa que todos los casos dentro del nodo pertenecen a la misma clase.

Un nodo mezclado tiene un Gini mayor que cero. Esto significa que dentro del nodo hay casos de distintas clases.

Pregunta 9.

Si un nodo tiene tres personas que buscan cargador y cero personas que no buscan cargador, ¿su Gini será alto o bajo?

Idea esperada.

Será bajo, específicamente cero, porque el nodo contiene una sola clase.

Pregunta 10.

Si un nodo tiene tres personas que buscan cargador y tres personas que no buscan cargador, ¿su Gini será alto o bajo?

Idea esperada.

Será más alto, porque el nodo está mezclado.

Cierre introductorio.

En resumen, un árbol de decisión funciona como una secuencia de preguntas. Cada pregunta intenta dividir los datos en grupos más ordenados. En este ejemplo, la pregunta:

$$\text{¿Batería} \leq 25\%?$$

separa perfectamente los casos observados. Por eso sería una buena primera pregunta para construir el árbol.

La lógica general es:

Datos mezclados $\rightarrow$ Pregunta de división $\rightarrow$ Grupos más puros $\rightarrow$ Predicción

Árboles de Decisión

1.1. ¿Qué es un Árbol de Decisión?

Un árbol de decisión es un modelo de aprendizaje supervisado utilizado para **clasificación o regresión**. Funciona dividiendo los datos en subgrupos mediante preguntas secuenciales del tipo “¿la variable x cumple cierta condición?”, formando una estructura de árbol donde:

- Cada **nodo interno** representa una condición sobre un atributo.
- Cada **rama** representa el resultado de esa condición.
- Cada **hoja** representa una predicción (clase o valor numérico).

1.2. ¿Cómo funciona?

1. Se parte con todos los datos en la **raíz** del árbol.
2. Se busca la mejor variable y el mejor valor de corte para dividir los datos.
3. Se crean dos ramas: una para los que cumplen la condición y otra para los que no.
4. Este proceso se repite recursivamente en cada rama.
5. El proceso se detiene cuando:
 - Todos los elementos son de la misma clase (nodo puro).
 - Se alcanza una profundidad máxima.
 - No hay ganancia significativa al seguir dividiendo.

1.3. Métricas para evaluar divisiones

1.3.1. Impureza de Gini.

$$Gini = 1 - \sum_{i=1}^k p_i^2$$

donde p_i es la proporción de datos de la clase i en un nodo. El Gini es 0 cuando el nodo es puro.

1.3.2. Entropía.

$$H = - \sum_{i=1}^k p_i \log_2(p_i)$$

Se utiliza en el algoritmo ID3. También mide el grado de mezcla de clases en un nodo. **1.4. Ventajas.**

- Son fáciles de interpretar y visualizar.
- No requieren normalización ni estandarización.
- Admiten datos numéricos y categóricos.
- Capturan relaciones no lineales.

1.5. Desventajas.

- Pueden sobreajustarse (*overfitting*) si no se poda o regula su profundidad.

- Son sensibles a pequeñas variaciones en los datos.
- Solo generan divisiones ortogonales (no curvas).

1.6. Ejemplo 1: Árbol con variable categórica.

Consideremos el siguiente conjunto de datos. Se quiere predecir si una persona aprobó o no aprobó, usando dos variables: **Edad** y **Estudia**.

Edad	Estudia	Aprobó
Joven	Sí	Sí
Joven	No	No
Adulto	Sí	Sí
Adulto	No	No

Pregunta inicial.

Si llega una nueva persona y queremos predecir si aprobó, ¿qué variable parece más útil: **Edad** o **Estudia**?

Análisis de la variable Edad.

Primero observamos qué ocurre si dividimos los datos según la variable **Edad**.

$$Edad = Joven$$

Edad	Estudia	Aprobó
Joven	Sí	Sí
Joven	No	No

En este grupo hay una persona que aprobó y una persona que no aprobó. Por lo tanto, el grupo no es puro.

$$Edad = Adulto$$

Edad	Estudia	Aprobó
Adulto	Sí	Sí
Adulto	No	No

En este grupo también hay una persona que aprobó y una persona que no aprobó. Por lo tanto, este grupo tampoco es puro.

Pregunta clave.

¿La variable **Edad** permite separar correctamente a quienes aprueban de quienes no aprueban?

Respuesta esperada.

No. Al dividir por edad, tanto el grupo de jóvenes como el grupo de adultos quedan mezclados.

Análisis de la variable Estudia.

Ahora observamos qué ocurre si dividimos los datos según la variable **Estudia**.

$$Estudia = Sí$$

Edad	Estudia	Aprobó
Joven	Sí	Sí
Adulto	Sí	Sí

En este grupo, todas las personas aprobaron. Por lo tanto, este grupo es puro.

$$Estudia = No$$

Edad	Estudia	Aprobó
Joven	No	No
Adulto	No	No

En este grupo, ninguna persona aprobó. Por lo tanto, este grupo también es puro.

Pregunta clave.

¿La variable **Estudia** permite separar correctamente a quienes aprueban de quienes no aprueban?

Respuesta esperada.

Sí. Al dividir por **Estudia**, se forman dos grupos completamente puros.

Conclusión del ejemplo.

La variable **Estudia** es mejor que la variable **Edad** para construir el primer nodo del árbol, porque separa perfectamente las clases:

- Si **Estudia** = **Sí**, entonces la predicción es **Aprobó**.
- Si **Estudia** = **No**, entonces la predicción es **No aprobó**.

Árbol resultante:

¿Estudia?

Sí -> Aprobó

No -> No aprobó

Interpretación pedagógica.

El árbol de decisión funciona como una pauta de preguntas. En este caso, basta una sola pregunta para clasificar correctamente todos los ejemplos:

¿La persona estudia?

Si la respuesta es sí, el árbol predice que aprueba. Si la respuesta es no, el árbol predice que no aprueba.

La variable **Edad** no fue seleccionada porque no ordena bien los datos. En cambio, la variable **Estudia** sí genera grupos puros. Esta es la idea central de los árboles de decisión: buscar la pregunta que deje los datos lo más ordenados posible.

1.7. Ejemplo 2: Árbol con variable numérica.

Consideremos el siguiente conjunto de datos. Se quiere predecir si un estudiante aprobó o no aprobó según sus horas de estudio.

Horas de estudio	Aprobó
2	No
4	No
6	Sí
8	Sí
10	Sí

Pregunta inicial.

Al observar los datos, ¿parece existir una relación entre las horas de estudio y la aprobación?

Respuesta esperada.

Sí. Los estudiantes que estudian pocas horas tienden a no aprobar, mientras que quienes estudian más horas tienden a aprobar.

Pregunta clave.

Como la variable es numérica, el árbol no puede preguntar:

$$\text{¿Horas de estudio} = 6?$$

o

$$\text{¿Horas de estudio} = 8?$$

para cada valor posible.

Entonces, ¿qué tipo de pregunta debería hacer?

Respuesta esperada.

Debe buscar un punto de corte.

Por ejemplo:

$$\text{¿Horas de estudio} \leq c?$$

donde c es algún valor que permita separar los datos.

Paso 1: Ordenar los datos.

Los datos ya se encuentran ordenados:

$$2, 4, 6, 8, 10$$

Paso 2: Buscar posibles cortes.

Los posibles puntos de corte se obtienen calculando los puntos medios entre observaciones consecutivas:

$$t_1 = \frac{2+4}{2} = 3$$

$$t_2 = \frac{4+6}{2} = 5$$

$$t_3 = \frac{6+8}{2} = 7$$

$$t_4 = \frac{8+10}{2} = 9$$

Por lo tanto, los posibles cortes son:

$$3, 5, 7, 9$$

Pregunta clave.

¿Por qué utilizamos puntos medios y no directamente los valores observados?

Respuesta esperada.

Porque el objetivo es separar observaciones consecutivas. El punto medio genera una frontera entre ambos grupos.

Paso 3: Analizar el corte $x = 5$.

Si elegimos:

$$¿\text{Horas de estudio} \leq 5?$$

obtenemos:

$$\text{Horas} \leq 5$$

Horas	Aprobó
2	No
4	No

Todos los estudiantes de este grupo no aprobaron.

Por lo tanto, el grupo es puro.

$$\text{Horas} > 5$$

Horas	Aprobó
6	Sí
8	Sí
10	Sí

Todos los estudiantes de este grupo aprobaron.

Por lo tanto, este grupo también es puro.

Pregunta clave.

¿Qué significa que ambos grupos sean puros?

Respuesta esperada.

Significa que el corte separa perfectamente las clases.

Comparación intuitiva con otros cortes.

Si utilizamos el corte:

$$x = 3$$

el grupo derecho contendría estudiantes que aprobaron y estudiantes que no aprobaron.

Por lo tanto, existiría mezcla de clases.

Si utilizamos el corte:

$$x = 9$$

el grupo izquierdo también contendría estudiantes que aprobaron y estudiantes que no aprobaron.

Nuevamente existiría mezcla de clases.

Pregunta clave.

¿Cuál de todos los cortes parece separar mejor los datos?

Respuesta esperada.

El corte en:

$$x = 5$$

porque genera dos grupos completamente puros.

Conclusión del ejemplo.

La mejor pregunta para construir el árbol es:

$$\text{¿Horas de estudio} \leq 5?$$

Si la respuesta es sí, el estudiante pertenece al grupo de quienes no aprobaron.

Si la respuesta es no, pertenece al grupo de quienes aprobaron.

$$\text{¿Horas de estudio} \leq 5? \Rightarrow \begin{cases} \text{Sí} & \rightarrow \text{No aprobó} \\ \text{No} & \rightarrow \text{Aprobó} \end{cases}$$

Árbol resultante:

¿Horas de estudio <= 5?

Sí -> No aprobó

No -> Aprobó

Interpretación pedagógica.

Mientras que en el ejemplo anterior el árbol debía escoger entre categorías (*Sí/No*), en este caso debe encontrar un valor numérico que divida mejor los datos.

La idea fundamental es la misma: encontrar la pregunta que produzca los grupos más puros posibles. Más adelante veremos que medidas como el índice de Gini permiten cuantificar formalmente qué tan buena es cada división.

Ejercicios

Ejercicio 1: Conjunto de Datos Reducido (5 datos). Dado el siguiente conjunto de datos, determine la mejor partición de los datos para un árbol de decisión y calcule la función de costo asociada a dicha partición utilizando el índice de Gini:

X	Y
-1.2	0
0.3	1
-0.8	0
0.6	1
1.0	1

Determine:

- El mejor punto de corte sobre la variable **X** para particionar los datos.
- La función de costo total utilizando el índice de Gini.

Ejercicio 2: Conjunto de Datos Extendido (9 datos). Dado el siguiente conjunto de datos, determine la mejor partición de los datos para un árbol de decisión y calcule la función de costo asociada a dicha partición utilizando el índice de Gini:

X	Y
1.23	1
-0.47	0
0.02	1
1.40	1
0.53	1
-0.97	0
0.70	0
-0.45	0
0.10	1

Determine:

- El mejor punto de corte sobre la variable **X** para particionar los datos.
- La función de costo total utilizando el índice de Gini.

Desarrollo de Ejercicios

Ejercicio 1: Conjunto de Datos Reducido (5 datos).

Dado el siguiente conjunto de datos:

X	Y
-1.2	0
0.3	1
-0.8	0
0.6	1
1.0	1

se desea encontrar el mejor punto de corte sobre la variable X para construir un nodo de un árbol de decisión.

Pregunta inicial.

¿Qué debe hacer el árbol de decisión en este problema?

Respuesta esperada.

Debe encontrar un valor de corte t tal que al preguntar:

$$X \leq t$$

los datos queden separados en dos grupos lo más puros posible.

Paso 1: Ordenar los datos según X .

Antes de calcular los cortes, se ordenan los datos de menor a mayor según X :

X	Y
-1.2	0
-0.8	0
0.3	1
0.6	1
1.0	1

Pregunta clave.

¿Por qué ordenamos los datos antes de calcular los cortes?

Respuesta esperada.

Porque los posibles puntos de corte se calculan entre valores consecutivos de la variable X .

Paso 2: Calcular los posibles puntos de corte.

Los posibles umbrales se obtienen calculando el punto medio entre cada par de valores consecutivos:

$$t_1 = \frac{-1,2 + (-0,8)}{2} = -1,0$$

$$t_2 = \frac{-0,8 + 0,3}{2} = -0,25$$

$$t_3 = \frac{0,3 + 0,6}{2} = 0,45$$

$$t_4 = \frac{0,6 + 1,0}{2} = 0,8$$

Por lo tanto, los posibles puntos de corte son:

$$-1,0, \quad -0,25, \quad 0,45, \quad 0,8$$

Pregunta clave.

¿Por qué usamos puntos medios y no directamente los valores observados?

Respuesta esperada.

Porque el corte debe separar dos observaciones consecutivas. El punto medio permite generar una frontera entre ambos valores.

Paso 3: Recordar la fórmula del índice de Gini.

Para un conjunto D con dos clases, el índice de Gini se calcula como:

$$Gini(D) = 1 - p_0^2 - p_1^2$$

donde:

$$p_0 = \text{proporción de datos de clase 0}$$

$$p_1 = \text{proporción de datos de clase 1}$$

La función de costo total para un corte t es:

$$Costo(t) = \frac{|D_{izq}|}{|D|} Gini(D_{izq}) + \frac{|D_{der}|}{|D|} Gini(D_{der})$$

Pregunta clave.

¿Qué significa que un grupo tenga $Gini = 0$?

Respuesta esperada.

Significa que el grupo es puro; es decir, todos sus elementos pertenecen a la misma clase.

Paso 4: Evaluar el corte $t = -1,0$.

La pregunta del árbol sería:

$$X \leq -1,0$$

La partición queda:

$$D_{izq} = \{(-1,2,0)\}$$

$$D_{der} = \{(-0,8,0), (0,3,1), (0,6,1), (1,0,1)\}$$

En el lado izquierdo hay un solo dato de clase 0:

$$Gini(D_{izq}) = 0$$

En el lado derecho hay 1 dato de clase 0 y 3 datos de clase 1:

$$p_0 = \frac{1}{4}, \quad p_1 = \frac{3}{4}$$

$$Gini(D_{der}) = 1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2$$

$$Gini(D_{der}) = 1 - \frac{1}{16} - \frac{9}{16} = \frac{6}{16} = 0,375$$

La función de costo es:

$$Costo(-1,0) = \frac{1}{5}(0) + \frac{4}{5}(0,375)$$

$$Costo(-1,0) = 0,30$$

Paso 5: Evaluar el corte $t = -0,25$.

La pregunta del árbol sería:

$$X \leq -0,25$$

La partición queda:

$$D_{izq} = \{(-1,2,0), (-0,8,0)\}$$

$$D_{der} = \{(0,3,1), (0,6,1), (1,0,1)\}$$

En el lado izquierdo todos los datos son clase 0:

$$Gini(D_{izq}) = 0$$

En el lado derecho todos los datos son clase 1:

$$Gini(D_{der}) = 0$$

Por lo tanto:

$$Costo(-0,25) = \frac{2}{5}(0) + \frac{3}{5}(0)$$

$$Costo(-0,25) = 0$$

Pregunta clave.

¿Qué significa obtener costo total igual a cero?

Respuesta esperada.

Significa que el corte separa perfectamente las clases.

Paso 6: Evaluar el corte $t = 0,45$.

La pregunta del árbol sería:

$$X \leq 0,45$$

La partición queda:

$$D_{izq} = \{(-1,2,0), (-0,8,0), (0,3,1)\}$$

$$D_{der} = \{(0,6,1), (1,0,1)\}$$

En el lado izquierdo hay 2 datos de clase 0 y 1 dato de clase 1:

$$p_0 = \frac{2}{3}, \quad p_1 = \frac{1}{3}$$

$$Gini(D_{izq}) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2$$

$$Gini(D_{izq}) = 1 - \frac{4}{9} - \frac{1}{9} = \frac{4}{9} \approx 0,444$$

En el lado derecho todos los datos son clase 1:

$$Gini(D_{der}) = 0$$

Entonces:

$$Costo(0,45) = \frac{3}{5} \left(\frac{4}{9} \right) + \frac{2}{5} (0)$$

$$Costo(0,45) = \frac{12}{45} = \frac{4}{15} \approx 0,267$$

Paso 7: Evaluar el corte $t = 0,8$.

La pregunta del árbol sería:

$$X \leq 0,8$$

La partición queda:

$$D_{izq} = \{(-1,2,0), (-0,8,0), (0,3,1), (0,6,1)\}$$

$$D_{der} = \{(1,0,1)\}$$

En el lado izquierdo hay 2 datos de clase 0 y 2 datos de clase 1:

$$p_0 = \frac{2}{4}, \quad p_1 = \frac{2}{4}$$

$$Gini(D_{izq}) = 1 - \left(\frac{2}{4} \right)^2 - \left(\frac{2}{4} \right)^2$$

$$Gini(D_{izq}) = 1 - \frac{1}{4} - \frac{1}{4} = 0,5$$

En el lado derecho hay un solo dato de clase 1:

$$Gini(D_{der}) = 0$$

Entonces:

$$\text{Costo}(0,8) = \frac{4}{5}(0,5) + \frac{1}{5}(0)$$

$$\text{Costo}(0,8) = 0,40$$

Paso 8: Comparar los costos.

Punto de corte	Costo total
-1,0	0,30
-0,25	0,00
0,45	0,267
0,8	0,40

Conclusión.

El mejor punto de corte es:

$$t = -0,25$$

porque tiene la menor función de costo:

$$\text{Costo}(-0,25) = 0$$

Por lo tanto, la regla del árbol es:

$$X \leq -0,25 \Rightarrow \begin{cases} \text{Sí} \rightarrow \text{Clase 0} \\ \text{No} \rightarrow \text{Clase 1} \end{cases}$$

Interpretación pedagógica.

Este corte funciona perfectamente porque deja todos los valores con clase 0 al lado izquierdo y todos los valores con clase 1 al lado derecho. Es decir, no queda mezcla de clases en ninguna rama.

Ejercicio 2: Conjunto de Datos Extendido (9 datos).

Dado el siguiente conjunto de datos:

X	Y
1.23	1
-0.47	0
0.02	1
1.40	1
0.53	1
-0.97	0
0.70	0
-0.45	0
0.10	1

se desea encontrar el mejor punto de corte sobre la variable X usando el índice de Gini.

Paso 1: Ordenar los datos según X .

X	Y
-0.97	0
-0.47	0
-0.45	0
0.02	1
0.10	1
0.53	1
0.70	0
1.23	1
1.40	1

Pregunta clave.

¿Qué diferencia se observa respecto al ejercicio anterior?

Respuesta esperada.

En este caso las clases no están separadas perfectamente, porque aparece un dato de clase 0 en $X = 0,70$ entre varios datos de clase 1.

Paso 2: Calcular los posibles puntos de corte.

$$t_1 = \frac{-0,97 + (-0,47)}{2} = -0,72$$

$$t_2 = \frac{-0,47 + (-0,45)}{2} = -0,46$$

$$t_3 = \frac{-0,45 + 0,02}{2} = -0,215$$

$$t_4 = \frac{0,02 + 0,10}{2} = 0,06$$

$$t_5 = \frac{0,10 + 0,53}{2} = 0,315$$

$$t_6 = \frac{0,53 + 0,70}{2} = 0,615$$

$$t_7 = \frac{0,70 + 1,23}{2} = 0,965$$

$$t_8 = \frac{1,23 + 1,40}{2} = 1,315$$

Paso 3: Evaluar cada punto de corte.

Para evitar repetir demasiadas tablas, se resume cada partición indicando la composición de clases a la izquierda y a la derecha.

Corte $t = -0,72$.

$$D_{izq} = \{0\}$$

$$D_{der} = \{0, 0, 1, 1, 1, 0, 1, 1\}$$

$$Gini(D_{izq}) = 0$$

En D_{der} hay 3 datos de clase 0 y 5 datos de clase 1:

$$Gini(D_{der}) = 1 - \left(\frac{3}{8}\right)^2 - \left(\frac{5}{8}\right)^2 = \frac{30}{64} = 0,46875$$

$$Costo(-0,72) = \frac{1}{9}(0) + \frac{8}{9}(0,46875) = 0,4167$$

Corte $t = -0,46$.

$$D_{izq} = \{0, 0\}$$

$$D_{der} = \{0, 1, 1, 1, 0, 1, 1\}$$

$$Gini(D_{izq}) = 0$$

En D_{der} hay 2 datos de clase 0 y 5 datos de clase 1:

$$Gini(D_{der}) = 1 - \left(\frac{2}{7}\right)^2 - \left(\frac{5}{7}\right)^2 = \frac{20}{49} \approx 0,4082$$

$$Costo(-0,46) = \frac{2}{9}(0) + \frac{7}{9}\left(\frac{20}{49}\right) = \frac{20}{63} \approx 0,3175$$

Corte $t = -0,215$.

$$D_{izq} = \{0, 0, 0\}$$

$$D_{der} = \{1, 1, 1, 0, 1, 1\}$$

$$Gini(D_{izq}) = 0$$

En D_{der} hay 1 dato de clase 0 y 5 datos de clase 1:

$$Gini(D_{der}) = 1 - \left(\frac{1}{6}\right)^2 - \left(\frac{5}{6}\right)^2 = \frac{10}{36} = \frac{5}{18} \approx 0,2778$$

$$Costo(-0,215) = \frac{3}{9}(0) + \frac{6}{9}\left(\frac{5}{18}\right) = \frac{5}{27} \approx 0,1852$$

Corte $t = 0,06$.

$$D_{izq} = \{0, 0, 0, 1\}$$

$$D_{der} = \{1, 1, 0, 1, 1\}$$

En D_{izq} hay 3 datos de clase 0 y 1 dato de clase 1:

$$Gini(D_{izq}) = 1 - \left(\frac{3}{4}\right)^2 - \left(\frac{1}{4}\right)^2 = 0,375$$

En D_{der} hay 1 dato de clase 0 y 4 datos de clase 1:

$$Gini(D_{der}) = 1 - \left(\frac{1}{5}\right)^2 - \left(\frac{4}{5}\right)^2 = \frac{8}{25} = 0,32$$

$$Costo(0,06) = \frac{4}{9}(0,375) + \frac{5}{9}(0,32) = 0,3444$$

Corte $t = 0,315$.

$$D_{izq} = \{0, 0, 0, 1, 1\}$$

$$D_{der} = \{1, 0, 1, 1\}$$

En D_{izq} hay 3 datos de clase 0 y 2 datos de clase 1:

$$Gini(D_{izq}) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = \frac{12}{25} = 0,48$$

En D_{der} hay 1 dato de clase 0 y 3 datos de clase 1:

$$Gini(D_{der}) = 1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2 = 0,375$$

$$Costo(0,315) = \frac{5}{9}(0,48) + \frac{4}{9}(0,375) = 0,4333$$

Corte $t = 0,615$.

$$D_{izq} = \{0, 0, 0, 1, 1, 1\}$$

$$D_{der} = \{0, 1, 1\}$$

En D_{izq} hay 3 datos de clase 0 y 3 datos de clase 1:

$$Gini(D_{izq}) = 0,5$$

En D_{der} hay 1 dato de clase 0 y 2 datos de clase 1:

$$Gini(D_{der}) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = \frac{4}{9} \approx 0,4444$$

$$Costo(0,615) = \frac{6}{9}(0,5) + \frac{3}{9}\left(\frac{4}{9}\right) = \frac{13}{27} \approx 0,4815$$

Corte $t = 0,965$.

$$D_{izq} = \{0, 0, 0, 1, 1, 1, 0\}$$

$$D_{der} = \{1, 1\}$$

En D_{izq} hay 4 datos de clase 0 y 3 datos de clase 1:

$$Gini(D_{izq}) = 1 - \left(\frac{4}{7}\right)^2 - \left(\frac{3}{7}\right)^2 = \frac{24}{49} \approx 0,4898$$

En D_{der} todos los datos son clase 1:

$$Gini(D_{der}) = 0$$

$$Costo(0,965) = \frac{7}{9} \left(\frac{24}{49}\right) + \frac{2}{9}(0) = \frac{8}{21} \approx 0,3810$$

Corte $t = 1,315$.

$$D_{izq} = \{0, 0, 0, 1, 1, 1, 0, 1\}$$

$$D_{der} = \{1\}$$

En D_{izq} hay 4 datos de clase 0 y 4 datos de clase 1:

$$Gini(D_{izq}) = 0,5$$

En D_{der} hay un solo dato de clase 1:

$$Gini(D_{der}) = 0$$

$$Costo(1,315) = \frac{8}{9}(0,5) + \frac{1}{9}(0) = 0,4444$$

Paso 4: Comparar todos los costos.

Punto de corte	Costo total
-0,72	0,4167
-0,46	0,3175
-0,215	0,1852
0,06	0,3444
0,315	0,4333
0,615	0,4815
0,965	0,3810
1,315	0,4444

Conclusión.

El menor costo corresponde al punto de corte:

$$t = -0,215$$

con costo total:

$$\text{Costo}(-0,215) = \frac{5}{27} \approx 0,1852$$

Por lo tanto, la mejor partición es:

$$X \leq -0,215 \Rightarrow \begin{cases} \text{Sí} \rightarrow \text{Clase 0} \\ \text{No} \rightarrow \text{Mayoría clase 1} \end{cases}$$

Interpretación pedagógica.

A diferencia del primer ejercicio, aquí no existe un corte que deje ambos grupos completamente puros. El mejor corte es aquel que deja el menor desorden posible.

El valor $t = -0,215$ separa perfectamente los tres primeros datos de clase 0 hacia la izquierda, pero en el lado derecho todavía queda un dato de clase 0 mezclado con varios datos de clase 1. Por eso el costo no es cero, aunque sí es el menor entre todos los candidatos.

Idea central.

Un árbol de decisión no busca una separación perfecta si esta no existe. Busca la mejor separación disponible según una medida de impureza, en este caso el índice de Gini.